

GUIDE 059 / À LIRE ET À UTILISER

Quatre garde-fous à poser avant de laisser un agent agir seul

MULTI-OUTILS · 5 MIN DE LECTURE

Quatre contraintes à mettre en place avant de laisser quoi que ce soit tourner sans surveillance, apprises à la dure.

Ce qui change avec un agent qui agit

Un agent capable d'agir n'a rien à voir avec un assistant qui se contente de répondre. Les modes de défaillance deviennent vite coûteux dès que des actions réelles sont en jeu.

Les quatre garde-fous

Premier garde-fou : une limite stricte de dépense et de nombre d'actions par exécution.

Deuxième : une liste blanche d'outils autorisés, plutôt qu'une liste noire d'outils interdits.

Troisième : un journal en ajout seul (jamais modifiable) de tout ce que l'agent a fait.

Quatrième, celui que presque tout le monde saute : un mode simulation, laissé actif pendant une semaine entière. L'agent décrit chaque action qu'il aurait prise, sans en exécuter aucune.

Ce que révèle la relecture

Relire ce journal en fin de semaine révèle presque toujours au moins une chose qu'on est très content que l'agent n'ait pas faite.