

Le mode « caveman » : jusqu'à 75 % de tokens en moins, même contenu

MULTI-OUTILS · 5 MIN DE LECTURE

Une astuce gratuite réduit fortement la consommation de tokens en forçant l'IA à répondre de façon minimaliste. Même réponse, beaucoup moins de mots.

Pourquoi ça marche

Atteindre rapidement sa limite d'usage sur un modèle avancé arrive souvent parce que chaque réponse s'étale sur plusieurs pages, sans que le contenu soit meilleur pour autant, juste plus long. L'astuce consiste à forcer un style de réponse dépouillé à l'extrême. La réduction de tokens peut atteindre 75 %, avec une qualité de fond identique.

Le verbiage poli type « je serais ravi de vous aider » et les transitions type « laissez-moi vous expliquer » pèsent en tokens sans apporter d'information. Les supprimer laisse le contenu utile intact, et sur les modèles les plus coûteux, ça change directement la facture d'usage.

Le prompt à activer

PROMPT À COPIER

Prompt : mode dépouillé

À partir de maintenant, dans cette conversation, tu réponds en mode « minimaliste ».

Règles :

- Pas de formules de politesse, pas de « je vais t'aider », pas de « bien sûr, voici ».
- Pas de transitions (« d'abord », « ensuite », « enfin »). Tu passes directement au point suivant.
- Phrases courtes, verbes à l'infinitif quand possible.
- Pas d'adverbes inutiles (« essentiellement », « en gros », « vraiment »).
- Si une liste suffit, tu fais une liste. Pas de paragraphe.
- Tu gardes 100 % du contenu utile. Tu ne sacrifies que l'enrobage.

Confirme en un mot, puis on continue.

Quand l'utiliser

Pour tout ce qui est opérationnel : check-lists, brouillons d'e-mails, plans d'action, code, audits. Garder le mode normal pour les sujets où la nuance compte (négociation, texte à charge émotionnelle, brief créatif).

À retenir

Le verbiage n'est pas de l'intelligence, c'est du remplissage. Ce prompt peut être enregistré comme style personnalisé, activable à la demande : de quoi doubler son autonomie d'usage sans changer de forfait.

Question fréquente

Est-ce que ça réduit vraiment la qualité ? Non. Sur les tâches de production, la qualité reste identique. C'est simplement moins agréable à lire.