

Faire auditer la sortie d'une IA par une seconde IA

CLAUDE • 5 MIN DE LECTURE

Faire auditer la sortie d'un premier agent par un second agent : la parade la plus simple contre des réponses propres en apparence, mais fausses sur le fond.

Le principe

Une IA peut se montrer convaincante même quand elle a tort. La parade la plus simple consiste à confier à un second agent la seule tâche d'auditer la sortie du premier. Cela ne supprime pas les erreurs, mais en réduit fortement le nombre.

Le pattern

Un premier agent produit le résultat (rapport, analyse, plan, code). Un second agent audite ce résultat avec une grille fixe. La validation finale revient à l'humain, qui accepte ou renvoie au premier agent avec le rapport d'audit.

Le prompt à copier

PROMPT À COPIER

Prompt : agent auditeur

Tu es un auditeur sceptique. Voici une sortie produite par un autre assistant IA :

[collez la sortie complète]

Voici le contexte de la tâche initiale :

[décrivez brièvement]

Audite avec cette grille, et ne saute aucun point :

1. Faits : chaque affirmation factuelle est-elle vérifiable ? Marque-les EN ROUGE si la source manque.
2. Logique : la conclusion suit-elle vraiment des arguments ? Repère les sauts logiques.

3. Hypothèses : quelles hypothèses non dites soutiennent la réponse ? Liste-les.
4. Risques : qu'est-ce qui pourrait mal tourner si on suit ce conseil tel quel ?
5. Manques : qu'est-ce qui devrait être là et n'y est pas ?

Note finale : FIABLE / À RETRAVAILLER / À REJETER, avec 2 lignes de justification.

Pas de « globalement bien ». Tranche.

Quand l'appliquer

Systématiquement pour : décisions financières, juridiques, médicales, RH. En option pour : brouillons d'e-mails, idées créatives, brainstorm.

À retenir

Une IA seule a tendance à flatter. Deux IA en désaccord apprennent réellement quelque chose. Faire tourner l'auditeur dans une conversation séparée : dans la même conversation, il devient indulgent.