

Trois façons dont une IA se trompe, et les prompts pour les corriger

MULTI-OUTILS · 5 MIN DE LECTURE

Hallucination, flatterie, biais : trois erreurs distinctes qui paraissent toutes crédibles. Trois prompts très courts permettent de les corriger dans n'importe quelle conversation.

Le constat de départ

Une IA ne « ment » pas au sens humain du terme. Mais elle se trompe de trois manières précises, qui ont toutes l'air crédibles. Sans savoir les distinguer, on finit par prendre de mauvaises décisions sur la base de phrases bien tournées.

1. L'hallucination

Le modèle invente une donnée, une citation, une étude. Cause : il prédit le mot suivant le plus probable, pas la vérité.

PROMPT À COPIER

Prompt : anti-hallucination

Avant de répondre, sépare ce que tu sais avec certitude (sources vérifiables) de ce que tu déduis ou supposes. Si une information n'a pas de source que tu peux nommer, dis « je ne sais pas » plutôt que de la formuler.

2. La flatterie

Le modèle donne raison à l'utilisateur parce qu'il est entraîné à plaire. C'est le biais le plus dangereux sur les décisions importantes.

PROMPT À COPIER

Prompt : anti-flatterie

Réponds comme un contradicteur qui n'a aucune envie d'être sympa. Trouve le meilleur argument CONTRE ma position. Ne valide rien sans l'avoir d'abord attaqué.

3. Le biais

Le modèle hérite des biais de ses données d'entraînement (occidental, anglophone, certaines opinions surreprésentées). Le résultat obtenu est un consensus, pas nécessairement la réalité.

PROMPT À COPIER

Prompt : anti-biais

Donne 3 angles de réponse depuis 3 contextes culturels différents. Indique pour chacun la perspective dominante et celle qui reste rare dans les sources occidentales.

À retenir

Douter juste assez.

Une IA n'est ni un oracle ni un menteur. C'est un brouillon brillant qui mérite l'esprit critique de son utilisateur, surtout dans les moments où on a le moins envie de l'exercer.